

CV HW1 实验报告

卢可 24300980057

April 17, 2026

Contents

1	实验任务	2
2	数据集与预处理	2
2.1	数据集简介	2
2.2	特征归一化	2
2.3	维度转换与验证集划分	2
2.4	Shuffle & Mini-batch	3
3	模型结构	3
4	参数查找	4
5	训练与可视化	4
5.1	训练曲线分析	4
5.2	权重可视化与空间模式	5
6	错例分析	6
7	实验结论	7

1 实验任务

本实验在不依赖 PyTorch、TensorFlow 等深度学习框架的前提下，仅使用 Python 基础库与 NumPy，从零手工搭建一个三层神经网络。模型将在经典的 Fashion-MNIST 服装数据集上进行训练，实现对 10 个服装类别的高精度图像分类。点击 [本实验代码GitHub链接](#) 查看实现细节。

2 数据集与预处理

本实验采用经典的 Fashion-MNIST 数据集。在将数据送入网络训练之前，对原始数据进行了预处理，以确保模型训练的稳定性和高效性。

2.1 数据集简介

Fashion-MNIST 包含 10 个类别的日常服装图像（如 T-shirt, Trouser, Pullover 等）。数据集共包含 70000 张图像，其中 60000 张用于训练验证，10,000 张用于独立测试。每张图像为 28×28 像素的单通道灰度图，原始像素值域为 $0 \sim 255$ 。

2.2 特征归一化

未经处理的像素绝对数值较大，若直接输入神经网络，极易在计算加权和时引发数值不稳定，或在激活函数（特别是 Sigmoid）两端发生梯度饱和与梯度消失现象。为此，本实验对所有图像的特征特征进行了线性归一化，将其等比例缩放至 $[0, 1]$ 区间：

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} = \frac{X}{255.0} \quad (1)$$

2.3 维度转换与验证集划分

由于本实验构建的 MLP 仅包含全连接层，无法直接提取二维图像的局部空间邻域特征。因此，在数据加载阶段，我们去除了图像的空间拓扑结构，将每张 28×28 的二维矩阵展平为长度为 784 的一维特征向量。

我们从原始训练集中随机抽样出 10000 条数据作为独立的验证集，剩余数据作为纯粹的训练集。

2.4 Shuffle & Mini-batch

在正式训练阶段，实验采用了Mini-batch训练策略，Batch Size设定为 64。在每一个Epoch 开始训练之前，利用 `np.random.permutation` 算法对全局训练数据进行随机打乱。该机制打破了数据输入序列中的潜在类别相关性，确保每个 Batch 内的数据分布尽可能贴近全局分布，从而有效防止模型在优化过程中陷入局部最优解。

3 模型结构

本实验实现了一个三层多层感知机，支持动态调整隐藏层维度，并集成了2种激活函数的切换机制，允许自定义隐藏层大小。

- **输入层**：接收展平后的图像向量 $x \in \mathbb{R}^{784}$ 。
- **第一隐藏层**：神经元数量由参数 `hidden_dim1` 决定，记为 h_1 。
- **第二隐藏层**：神经元数量由参数 `hidden_dim2` 决定，记为 h_2 。
- **输出层**：对应 10 个服装类别， $y \in \mathbb{R}^{10}$ 。

这种参数化设计确保了模型可以通过网格搜索在参数空间内进行自动化的性能调优。

模型内置了两种激活函数选项：**ReLU** 与 **Sigmoid**。

反向传播公式分别如下：

1. **ReLU**:

$$f(x) = \max(0, x), \quad f'(x) = \begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases} \quad (2)$$

2. **Sigmoid**:

$$f(x) = \frac{1}{1 + e^{-x}}, \quad f'(x) = f(x) \cdot (1 - f(x)) \quad (3)$$

模型支持通过反向传播计算梯度。

对于任意全连接层 l ，其梯度流向定义为：

$$\begin{aligned} \delta^{(l)} &= \frac{\partial L}{\partial z^{(l)}} \\ \frac{\partial L}{\partial W^{(l)}} &= (a^{(l-1)})^T \cdot \delta^{(l)} + \lambda W^{(l)} \\ \frac{\partial L}{\partial b^{(l)}} &= \sum_{batch} \delta^{(l)} \end{aligned} \quad (4)$$

其中 $\delta^{(l)}$ 是从下一层回传的误差项， λ 为 L2 正则化系数。

4 参数查找

通过网格搜索测试了多种超参数组合，部分搜索结果如下表所示：

Table 1: 多维度超参数对模型性能的影响

分析维度	变量取值	固定参数 (其它)	验证集最高准确率
学习率 (LR)	0.15	$hd = (256, 56), WD = 0.0001$	89.78%
	0.10		88.45%
	0.01		82.12%
第一隐层 (hd1)	256	$LR = 0.15, hd2 = 56, WD = 0.0001$	89.78%
	128		87.23%
第二隐层 (hd2)	56	$LR = 0.15, hd1 = 256, WD = 0.0001$	89.78%
	128		88.79%
	64		89.21%
权重衰减 (WD)	0.0001	$LR = 0.15, hd = (256, 56)$	89.78%
	0.001		88.10%
	0.01		85.34%

5 训练与可视化

根据网格搜索结果，选取最优超参数组合：LR: 0.15, hidden dim1: 256, hidden dim2: 56, weight decay: 0.0001) 进行最终训练。在模型训练阶段，使用**随机梯度下降**算法，并引入了**学习率衰减**与**L2 正则化**。

5.1 训练曲线分析

图 1 展示了在训练过程中，训练集和验证集上的 Loss 曲线，以及验证集上的 Accuracy 曲线。




Figure 1: 训练集与验证集上的 Loss 及 Accuracy 曲线

观察训练曲线可以发现，在第 12 个 Epoch 之后，训练集 Loss 依然保持下降趋势并最终下到 0.20 以下，然而验证集 Loss 停止下降并开始在 0.30 附近呈现出轻微的过拟合迹象。我们保存了其在第 16 轮达到性能峰值时的模型权重 (best_model.pkl) 作为最终模型参数。该模型在独立测试集上取得 89.78% 的最终准确率。

5.2 权重可视化与空间模式

为了探究模型学到的特征，我们将第一层隐藏层的权重矩阵恢复至 28×28 的图像尺寸，选取了 40 个神经元进行可视化，如图 2 所示。




Figure 2: 第一层隐藏层部分神经元权重可视化

神经元展现出了对服装宏观空间分布的捕获能力：部分神经元在图像中心区域形成了明显的正/负向响应簇，而边缘区域的权重趋于零值，证明模型自动识别并忽略了背景噪声。N189明显体现网络学习到了 Dress 的轮廓，N196明显体现网络学习到了 Pullover 的轮廓，N255明显体现网络学习到了 Trousers 的轮廓。

6 错例分析

尽管模型取得了较好的准确率，但在某些特定类别上仍存在混淆。图 3 展示了模型在独立测试集上的典型分类错误样本。



Figure 3: 测试集典型分类错例图示

观察错例分析图可以看出，分类错误主要集中在具有高轮廓相似度的类别之间。在低分辨率灰度空间下，服装的细粒度特征被严重模糊，导致判断出错。例如，Shirt, T-shirt, Pullover，和 Sandal, Sneaker 都因为外形相似而容易互相混淆，甚至连带背带的

Bag 也会因轮廓被误判为 T-shirt。这说明 MLP 由于缺乏卷积操作的局部感受野，无法有效提取平移不变的细节特征。

得到混淆矩阵如下表所示：

Table 2: 测试集混淆矩阵

True \ Pred	0	1	2	3	4	5	6	7	8	9
T-shirt/top	816	3	17	24	5	0	126	1	8	0
Trouser	1	974	1	18	2	0	2	0	2	0
Pullover	17	0	810	11	114	1	47	0	0	0
Dress	19	8	20	889	27	0	32	0	4	1
Coat	0	1	78	35	845	0	40	0	1	0
Sandal	0	0	0	1	0	956	0	25	1	17
Shirt	97	3	99	31	87	0	670	0	13	0
Sneaker	0	0	0	0	0	15	0	954	1	30
Bag	5	1	3	7	4	3	2	4	971	0
Ankle boot	0	0	0	0	0	5	1	29	0	965

7 实验结论

本实验成功实现了基于纯 NumPy 的三层 MLP 分类器，完整走通了数据预处理、前向与反向传播推导、超参数搜索、以及模型评估的全流程。模型在测试集上达到 88.5% 的准确率，在细粒度特征区分与平移不变性上仍然存在固有缺陷。